

Relatório Explicativo: Ensinando uma Inteligência Artificial a Classificar Vidros

Nomes dos alunos: Vitória Ayres - 2086138

Leticia Ribeiro - 2034293

Disciplina – Professora: Natália - Inteligência Artificial Classificadores

Dataset - UCI Glass <https://www.kaggle.com/datasets/uciml/glass>

Resumo

Este estudo desenvolveu uma inteligência artificial que identifica tipos de vidro com base em sua composição química, visando acelerar a triagem na reciclagem industrial e apoiar investigações policiais. Utilizando uma base de dados com 214 amostras, o projeto testou os algoritmos KNN, SVM e Naive Bayes, identificando que o Sódio, o Magnésio e o Alumínio são os elementos mais importantes para a diferenciação. O modelo SVM apresentou o melhor desempenho, atingindo 72% de acerto geral, e o principal desafio apontado foi a falta de dados sobre vidros mais raros, o que limita a precisão do sistema nas categorias menos comuns.

Introdução

Este texto explica o uso da inteligência artificial para identificar tipos de vidro a partir de sua composição química, uma tecnologia com impacto direto na investigação forense — para rastrear a origem de fragmentos em cenas de crime — e na reciclagem industrial, automatizando a separação de materiais. Para treinar o sistema, a metodologia utilizou um catálogo de dados reais, analisou a relevância dos componentes químicos e testou três algoritmos diferentes para descobrir qual deles aprendia de forma mais eficiente e cometia menos erros ao avaliar novas amostras.

Descrição Geral e Pré-Processamento do Dataset

O conjunto de dados selecionado para esta investigação foi o UCI Glass Classification, amplamente reconhecido na literatura científica de computação. Ele é composto por um volume total de **214 amostras** de vidro. Para cada uma das amostras, foram extraídas **9 variáveis preditas (features químicas)** que alimentam o modelo:

- **RI**: Índice de Refração (propriedade física da luz ao atravessar o vidro)
- **Elementos Químicos (em percentual de peso)**: Sódio(Na), Magnésio(Mg), Alumínio(Al), Silício(Si), Potássio(K), Cálcio(Ca), Bário(Ba) e Ferro(Fe).

A variável alvo (target) que a IA deve adivinhar chama-se **Type (representando a categoria do vidro)**. Uma restrição mapeada na base de dados é a ausência total de amostras da Classe 4, limitando o escopo preditivo às demais categorias.

Tabela 1 – Amostra estrutural das variáveis preditivas e alvo.

Índice	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type
0	152.101	13.64	4.49	1.10	71.78	0.06	8.75	0.0	0.0	1
1	151.761	13.89	3.60	1.36	72.73	0.48	7.83	0.0	0.0	1
2	151.618	13.53	3.55	1.54	72.99	0.39	7.78	0.0	0.0	1
3	151.2	13.21	3.69	1.29	72.61	0.57	8.22	0.0	0.0	1
4	151.21	13.21	3.62	1.24	73.08	0.55	08.07	0.0	0.0	1

Ao realizar o censo volumétrico interno da base de dados, detectou-se um fenômeno conhecido como **desbalanceamento crítico de classes**. Como demonstrado na Tabela 2, há uma disparidade gigantesca na quantidade de exemplos disponíveis para cada tipo de vidro:

Tabela 2 – Distribuição volumétrica de amostras por tipo de vidro.

Posição	Categoria Cadastrada	Volume Absolute (N)	Impacto Teórico no Aprendizado da IA
1º	Tipo 2 (Vidro predial comum)	76	<i>Alta representatividade: aprendizado facilitado e rico em detalhes.</i>
2º	Tipo 1 (Vidro automotivo)	70	<i>Alta representatividade: padrões químicos facilmente mapeados.</i>
3º	Tipo 7 (Faróis e lâmpadas)	29	<i>Média representatividade: Amostragem moderada.</i>
4º	Tipo 3 (Vidros especiais)	17	<i>Baixa representatividade: dados escassos; propensão a erros.</i>
5º	Tipo 5 (Vidros de recipientes)	13	<i>Raro: Histórico muito restrito para generalização.</i>
6º	Tipo 6 (Vidros de mesa)	9	<i>Crítico: Amostragem mínima; extremo desafio preditivo.</i>

Para evitar que os modelos apenas decorem os dados (**overfitting**) e garantir testes confiáveis, a base de dados foi dividida de forma proporcional (estratificada) em três partes.

- **Treino (59.8% – 128 amostras):** Usado para ensinar os algoritmos.
- **Validação (20.1% – 43 amostras):** Usado para ajustar as configurações dos modelos.
- **Teste (20.1% – 43 amostras):** Dados inéditos usados como uma "prova final" para avaliar o desempenho real.

Em seguida, aplicamos a normalização **StandardScaler**, que padroniza a escala de todas as variáveis. Esse passo é essencial para algoritmos como KNN e SVM, pois impede que elementos com valores numericamente mais altos (como Silício, em torno de 70%) dominem o cálculo de distância e apaguem a importância de elementos em menor quantidade (como o Ferro).


Análise Exploratória de Dados (EDA) e Visualização Gráfica

A análise inicial usou estatística e gráficos para entender o comportamento das amostras de vidro. Com o método do **Intervalo Interquartil (IQR)**, foram identificados os valores atípicos (outliers) — que são composições fora do padrão:

- **Magnésio (Mg):** 0 amostras atípicas (0.0%), mostrando-se muito estável.
- **Sódio (Na):** 7 amostras atípicas (3.3%).
- **Alumínio (Al):** 18 amostras atípicas (8.4%), sendo o elemento com maior variação anômala.

Para visualizar a dispersão dessas anomalias químicas, foram gerados os gráficos descritos a seguir:

Diagramas de Dispersão e Detecção de Outliers: Tipo vs Elementos Químicos (Mg, Al, Na)




Insight Analítico

A análise confirmou que o **Sódio (Na)**, o **Magnésio (Mg)** e o **Alumínio (Al)** são as variáveis mais importantes para separar e identificar os diferentes tipos de vidro.

Para mostrar como esses dados se distribuem na prática, a imagem abaixo apresenta o comportamento estatístico detalhado através de diagramas Boxplot

Diagramas Boxplot de distribuição e dispersão de dados estruturais



- **Boxplot A (Distribuição Ampla):** Mostra que os dados variam de forma constante do início ao fim da escala, sem valores isolados fora do padrão (outliers). Isso indica um grupo com características bem diversas entre si.
- **Boxplot B (Maior Dispersão):** Também não possui outliers, mas a caixa e as hastes mais longas mostram que os dados estão ainda mais espalhados por toda a faixa de valores, sem se concentrarem em um único ponto.

Arquitetura de Pré-Processamento e Modelagem

Para assegurar a idoneidade científica e a capacidade de generalização dos testes, os dados passaram pelas seguintes etapas regulamentares de engenharia:

1 - Divisão com Estratificação: Garante que a proporção original das classes (Tabela 2) seja mantida perfeitamente em todas as partições de dado

- **Treino:** 128 amostras (59.8% do dataset)
- **Validação:** 43 amostras (20.1% do dataset)
- **Teste:** 43 amostras (20.1% do dataset).

2- Normalização Espacial: Foi empregado o método **StandardScaler** essencial para equalizar a escala de todas as grandezas químicas e físicas (RI, Na, Mg, etc.). Este processo é obrigatório para o funcionamento correto de modelos baseados em cálculo de distância geométrica e margem espacial, como KNN e SVM.

O estudo realizou um benchmark comparativo entre três arquiteturas de classificação supervisionada:

- **KNN:** (*K-Neighbors Classifier*, parametrizado com $K=3$)
- **SVM:** (*Support Vector Classifier*, configurado com Kernel= rbf e penalidade $C=10$)
- **Naive Bayes** (*GaussianNB*, algoritmo probabilístico gaussiano)

Resultados e Análise Comparativa dos Classificadores

Após a submissão dos modelos preditivos à base de dados de teste (completamente inédita para as redes), as métricas de performance global foram computadas e estruturadas na Tabela 3

Resultados e Análise Comparativa dos Classificadore

Classificador	Acurácia Global	Precisão Macro	Recall Macro	F1-Score Macro
KNN (k=3)	0.7209 (72.09%)	0.71	0.57	0.59
SVM (RBF, C=10)	0.7209 (72.09%)	0.62	0.62	0.61
Naive Bayes	0.5581 (55.81%)	0.38	0.52	0.41

Para validar a estabilidade estatística real e mitigar vieses de partição aleatória, os algoritmos foram submetidos ao processo de **Validação Cruzada (Cross-Validation)**:

- **KNN:** Média obtida = 0.6009 (~ 0.0725)
- **SVM:** Média obtida = 0.6486 (~ 0.1309)
- **Naive Bayes= Média obtida = 0.4434 (~ 0.2374)**

Análise Comparativa do Melhor Classificador: Embora os modelos KNN e SVM tenham registrado um empate matemático na acurácia bruta de teste (72.09%), o **SVM (Kernel RBF, C=10)**

consolidou-se como o classificador mais robusto e eficiente. O critério técnico de decisão baseia-se no seu maior F1-Score Macro (0.61) e no melhor desempenho médio mantido na validação cruzada (0.6486). O SVM exibiu maior maturidade e equilíbrio geral entre as categorias, evitando o comportamento do KNN, que inflou sua acurácia focando apenas nas classes fáceis (majoritárias) enquanto falhava severamente nas minoritárias.

Diagnóstico de Erros e Padrões de Confusão

Para mapear os gargalos operacionais do sistema, as Matrizes de Confusão foram extraídas e estão esquematizadas na Figura 3, evidenciando o comportamento absoluto e o comportamento normalizado em percentual.

Painel de Matrizes de Confusão para análise de erros interclasses

1. Matriz de Confusão Absoluta — Naive Bayes			
	Pred: C1	Pred: C2	Pred: C3
Real: C1	[14]	0	0
Real: C2	2	[10]	0
Real: C3	2	7	[0]
2. Matriz de Confusão Normalizada (%) — Naive Bayes			
	Pred: C1	Pred: C2	Pred: C3
Real: C1	[67.0%]	13.0%	6.0%
Real: C2	6.0%	[40.0%]	0.0%
Real: C3	0.0%	67.0%	[0.0%]
3. Matriz de Confusão Absoluta — KNN Classifier			
	Pred: C1	Pred: C2	Pred: C3
Real: C1	[13]	1	0
Real: C2	4	[10]	1
Real: C3	3	3	[0]

A interpretação das matrizes revela de forma clara onde a Inteligência Artificial encontra dificuldades de triagem:

- **Classes Mais Confundidas:** As maiores taxas de erro ocorrem de maneira cruzada e sistêmica entre as fronteiras da **Classe 1 e da Classe 2**.
- **Gargalo da Classe 3:** O vidro pertencente ao "**Tipo 3**" é frequentemente classificado de forma errônea como pertencente às Classes 1 e 2, gerando um baixíssimo índice de Recall.
- **Causa Raiz:** Esse fenômeno é justificado diretamente pelo desbalanceamento crítico mapeado na EDA. Como a máquina tem uma quantidade massiva de exemplos das classes 1 e 2 para estudar, ela herda um viés estatístico estrutural, tendendo a ignorar os padrões da classe minoritária (Tipo 3) nas zonas de alta sobreposição química.

Considerações Finais

O fluxo de trabalho técnico que desenvolvemos — que passou pelas etapas de análise inicial dos dados, preparação e normalização das informações e testes comparativos entre modelos — funcionou muito bem. Esse processo se mostrou maduro, seguro e totalmente capaz de gerar resultados constantes e confiáveis para resolver o desafio de classificar os diferentes tipos de vidros.

Olhando para os resultados e para as evidências numéricas que coletamos, ficou claro que o algoritmo SVM com Kernel RBF é a escolha mais estável. Por isso, ele é o modelo que recomendamos para colocar o sistema em funcionamento na prática. Apesar desse bom desempenho, conseguimos identificar o principal ponto fraco do modelo atual: a grande diferença na quantidade de dados entre as

categorias (o desbalanceamento). É justamente essa falta de exemplos de algumas categorias que faz o sistema se confundir na hora de prever os tipos mais raros de vidro.

Para que o projeto evolua e possa ser usado com segurança em indústrias ou em perícias criminais, o próximo passo obrigatório é focar na coleta de novos dados. Precisamos aumentar a quantidade de amostras especificamente daquelas classes que aparecem pouco, como os Tipos 3, 5 e 6. Esse reforço na base de dados vai corrigir as distorções que encontramos nas matrizes de confusão, trazendo a precisão e a segurança necessárias para que o sistema seja aplicado em situações reais e críticas.

Link Oficial de Acesso ao Repositório do Código-Fonte: [Acesso Completo ao Script de Desenvolvimento no Google Colab](#)